

Estimation distribuée d'une espérance conditionnelle

Igor Colin

30 juin 2014

Rappels

Estimation de fonction

Objectif et formulation

- ▶ Objectif : regrouper les utilisateurs par centres d'intérêts communs
- ▶ Notations :
 - ▶ $(X_i)_{1 \leq i \leq n}$: caractéristiques des utilisateurs (musiques, historique des conversations, etc.)
 - ▶ $D : (X, Y) \mapsto D(X, Y)$: fonction de dissimilarité entre deux vecteurs de caractéristiques
 - ▶ P : partition des utilisateurs
 - ▶ Φ_P : fonction d'appartenance au même *cluster*

Problème

- Nouvel objectif : trouver la solution du problème

$$\min_P w(P) = \frac{1}{n} \sum_{i=1}^n \left(\frac{1}{n} \sum_{j=1}^n D(X_i, X_j) \Phi_P(X_i, X_j) \right)$$


- Idée : estimer $f : x \mapsto \mathbb{E}[D(x, X) \Phi_P(x, X)]$
- Contrainte : les $(X_i)_{1 \leq i \leq n}$ ne sont pas simultanément accessibles

Rappels

Estimation de fonction


Méthode générale de regression

- ▶ Notations :
 - ▶ f : fonction à estimer



Méthode générale de regression


- ▶ Notations :
 - ▶ f : fonction à estimer
 - ▶ $\{(x_i, f(x_i))\}_{1 \leq i \leq n}$: observations



Méthode générale de regression

► Notations :


- f : fonction à estimer
- $\{(x_i, f(x_i))\}_{1 \leq i \leq n}$: observations
- $\hat{f} : (x; \theta) \mapsto \hat{f}(x; \theta)$: estimateur



Méthode générale de regression

► Notations :


- f : fonction à estimer
- $\{(x_i, f(x_i))\}_{1 \leq i \leq n}$: observations
- $\hat{f} : (x; \theta) \mapsto \hat{f}(x; \theta)$: estimateur
- $\hat{R} : \theta \mapsto \hat{R}(\theta)$: risque empirique



Méthode générale de regression

- ▶ Notations :
 - ▶ f : fonction à estimer
 - ▶ $\{(x_i, f(x_i))\}_{1 \leq i \leq n}$: observations
 - ▶ $\hat{f} : (x; \theta) \mapsto \hat{f}(x; \theta)$: estimateur
 - ▶ $\hat{R} : \theta \mapsto \hat{R}(\theta)$: risque empirique
- ▶ Objectif : trouver θ^* solution de

$$\min_{\theta \in \Theta} \hat{R}(\theta)$$



Exemple

- ▶ Exemple : estimation polynomiale
 - ▶ $\hat{f} : (x; \theta) \mapsto \theta_0 + \theta_1 x + \theta_2 x^2$,
 - ▶ $\hat{R}(\theta) = \frac{1}{2n} \sum_{i=1}^n \left(\hat{f}(x_i) - f(x_i) \right)^2$
- ▶ Qualité dépendante du choix de \hat{f}




FIGURE: \hat{f} adaptée.




FIGURE: \hat{f} non adaptée.

Application au problème initial

- ▶ Fonction à estimer : $f : x \mapsto \mathbb{E} [D(x, X)\Phi_P(x, X)]$
- ▶ Risque empirique : moindres carrés
- ▶ Estimateur à noyaux :

$$\hat{f}(x; \theta, \mathbf{w}, a) = a + \sum_{j=1}^m w_j K(x - \theta_j)$$

où K est un noyau gaussien.




FIGURE: Noyau gaussien 1D








FIGURE: Noyau gaussien 2D

Résultats





- ▶ Application :
 - ▶ $D : (x, y) \mapsto \|x - y\|_2$
 - ▶ $(X_i)_{1 \leq i \leq n}$: n tirages d'un mélange de gaussiennes
 - ▶ Observations empiriques $\tilde{f}(x_i) = \frac{1}{n} \sum_{j=1}^n D(x_i, x_j) \Phi_p(x_i, x_j)$
- ▶ Objectif :

$$\min_{\theta, w, a} \hat{R}(\theta, w, a) = \frac{1}{2n} \sum_{i=1}^n \left(\hat{f}(x; \theta, w, a) - \tilde{f}(x_i) \right)^2$$

Résultats optimisation globale



Résultats optimisation distribuée



Contrainte supplémentaire

- ▶ $\tilde{f}(X_i)$ non accessible
- ▶ Idée : si l'agent i a accès aux caractéristiques $(X_j)_{j \in \mathcal{A}_i}$ ($i \in \mathcal{A}_i$), il peut :
 - ▶ estimer la distribution des X à partir des observations accessibles
 - ▶ utiliser le risque R_i :

$$R_i : (\theta, w, a) \mapsto \mathbb{E}_{\mu_i} \left[\left(\hat{f}(x; \theta, w, a) - \mathbb{E}_{\mu_i}[D(x, X)\Phi_P(x, X)] \right)^2 \right]$$

- ▶ Le problème devient alors

$$\min_{\theta, w, a} \frac{1}{n} \sum_{i=1}^n R_i(\theta, w, a)$$

Résultats